

Matriz de Costos y Optimización

Ecosistema Autónomo de Generación, Validación y Distribución de Contenidos - Verte Bien
Entrega Final - AI Automation | Coderhouse

Objetivo. Justificar la elección del modelo y las técnicas de optimización con datos reales del workflow, diferenciando ahorro medido, límites preventivos y estrategias futuras para procesamiento masivo.

1. Modelo elegido y precios de referencia

El workflow productivo utiliza **GPT-5 mini** porque la tarea está bien definida, usa contexto RAG acotado y exige una salida estructurada. Para el cálculo de las ejecuciones se utilizaron las tarifas estándar de texto de GPT-5 mini: **US\$0,25 por 1M tokens de entrada, US\$0,025 por 1M de entrada cacheada y US\$2,00 por 1M de salida.** El modelo soporta Responses API, Structured Outputs y Batch.

Opción	Entrada / 1M	Cache / 1M	Salida / 1M	Uso recomendado en este proyecto	Decisión
GPT-5 nano	US\$0,05	US\$0,005	US\$0,40	Clasificación o tareas simples de alto volumen.	Alternativa para tareas auxiliares; no es el generador principal.
GPT-5 mini	US\$0,25	US\$0,025	US\$2,00	Generación estructurada con contexto y reglas claras.	ELEGIDO: equilibrio entre capacidad, costo y latencia.
GPT-5	US\$1,25	US\$0,125	US\$10,00	Razonamiento más exigente o tareas agentic complejas.	No necesario para este caso; costo muy superior.

2. Evidencia experimental de optimización

Las siguientes mediciones provienen de ejecuciones reales registradas en Airtable. Se mantuvo la misma idea/contexto de prueba y se fueron ajustando parámetros del nodo OpenAI.

Configuración	Entrada	Salida	Total	Costo USD	Duración ms	Lectura
Base: Reasoning Medium, sin límite	455	663	1.118	0,001440	14.670	Punto de referencia.
Reasoning Low	455	345	800	0,000804	4.976	Menor razonamiento para una tarea acotada.
Low + Max Tokens 600	455	308	763	0,000730	5.596	Techo preventivo; evita salidas descontroladas.
Low + 600 + JSON Schema	507	308	815	0,000743	5.448	Más estructura; leve aumento de entrada.
Schema + processor corregido	507	317	824	0,000761	4.972	Salida estructurada procesada correctamente.
Cache key, prueba 1	507	353	860	0,000833	6.626	Cached tokens observados: 0.
Cache key, prueba 2	507	303	810	0,000733	4.746	Cached tokens observados: 0.

Resultado medido. Comparando la configuración base con la ejecución Low + límite de 600 tokens: el costo bajó de US\$0,001440 a US\$0,000730, una reducción aproximada del **49,3%**; los tokens totales bajaron un **31,8%**; y la duración pasó de 14.670 ms a 5.596 ms, una reducción aproximada del **61,9%**.

Precaución metodológica. No se atribuye la diferencia 345 → 308 tokens exclusivamente al límite de 600, porque ambas respuestas quedaron por debajo del máximo y existe variabilidad natural entre generaciones. El límite funciona principalmente como control presupuestario y de longitud.

3. Matriz de decisión por tarea

Tarea	Volumen / urgencia	Modelo / modalidad	Motivo	Política de costo
Generar borrador para HITL	Bajo-medio / interactivo	GPT-5 mini - Responses API	Necesita calidad suficiente, reglas médicas/brand y JSON confiable.	Reasoning Low + Max 600 + Verbosity Low +
Clasificación auxiliar futura	Alto / rápida	GPT-5 nano	Adecuado para clasificación/resumen simple y mucho más barato.	Usar solo si la tarea no requiere la calidad del
Lectura o razonamiento complejo futuro	Bajo / no rutinario	GPT-5 o modelo superior evaluado	Reservar mayor capacidad para casos realmente complejos.	Escalar modelo por excepción, no por defecto
Generación masiva no urgente	Alto / hasta 24 h	Batch API + modelo adecuado	Procesamiento asíncrono sin necesidad de respuesta inmediata.	50% de descuento frente a API síncrona.

4. Estrategia Batch para volumen masivo

La ruta HITL actual **no utiliza Batch** porque la revisión humana necesita una respuesta inmediata. Batch se documenta como estrategia de escalamiento para tareas no urgentes, por ejemplo preparar cientos de borradores para revisión posterior. OpenAI indica que Batch procesa solicitudes de forma asíncrona, apunta a completarlas dentro de 24 horas y ofrece un **50% de descuento** frente a las APIs síncronas.

Escenario simulado	Costo unitario de referencia	500 contenidos	Ahorro
API síncrona	≈ US\$0,00075	≈ US\$0,3750	—
Batch API (-50%)	≈ US\$0,000375	≈ US\$0,1875	≈ US\$0,1875

Supuesto del ejemplo: se usa US\$0,00075 como costo unitario representativo de las ejecuciones optimizadas observadas. Es una simulación de planificación, no un gasto Batch medido en este workflow.

5. Prompt caching y conclusión

El nodo mantiene una **Prompt Cache Key estable** (verte-bien-contenidos-v1) y registra **Tokens Cacheados**. En las pruebas realizadas el valor observado fue 0, por lo que **no se contabiliza ningún ahorro real por caché**. La arquitectura queda instrumentada para medirlo si aparece en ejecuciones futuras.

Conclusión. La principal optimización demostrada no depende de una estimación: surge de ejecuciones reales. GPT-5 mini con Reasoning Low y límites de salida redujo aproximadamente a la mitad el costo de la prueba base, manteniendo salida estructurada y HITL. Para escala masiva no urgente, Batch agrega una segunda palanca de ahorro del 50%.

Fuentes de precios verificadas (10/09/2026): documentación oficial del modelo GPT-5 mini y FAQ oficial de OpenAI Batch API. Los valores de ejecuciones, tokens, costos y tiempos provienen de la instrumentación del proyecto.