

Seguridad, Resiliencia y Human-in-the-loop

Ecosistema Autónomo de Generación, Validación y Distribución de Contenidos - Verte Bien
Entrega Final - AI Automation | Coderhouse

Objetivo. Documentar los controles que reducen exposición de datos, evitan ejecuciones no deseadas, registran fallos y bloquean la acción crítica hasta obtener una decisión humana válida.

1. Principios de seguridad aplicados

Control	Implementación	Riesgo mitigado
Minimización de datos	El flujo procesa Idea Semilla, contexto RAG y metadatos operativos necesarios. La Shared View pública debe ocultar identificadores internos innecesarios.	Exposición innecesaria de información.
Credenciales fuera del contenido	Tokens/API Keys se administran mediante credenciales de n8n. No se incluyen secretos en prompts, mensajes Slack ni JSON de negocio.	Filtración de secretos.
Prompt con restricciones	La IA recibe reglas explícitas: no inventar tratamientos, precios, promociones, diagnósticos o resultados; no garantizar resultados médicos.	Alucinaciones o comunicación médica inadecuada.
Salida estructurada	OpenAI devuelve JSON Schema con campos definidos y additionalProperties=false.	Respuestas ambiguas o difíciles de procesar.
HITL obligatorio	Todo borrador generado lleva requiere_revision=true y se envía a Slack antes de la acción crítica.	Publicación automática no supervisada.
Trazabilidad	Airtable conserva ejecuciones, fuentes RAG, costos, duración, resultado y errores.	Falta de auditoría.

2. Prevención de bucles y ejecuciones indebidas

El Airtable Trigger puede activarse nuevamente cuando el propio workflow modifica el registro. Para impedir un bucle, el primer filtro **¿Estado Generando?** solo deja continuar registros cuyo Estado sea exactamente **Generando**. Cuando el sistema cambia el estado a En revision, Publicado, Rechazado o Error, una nueva activación queda bloqueada.

En el workflow HITL existe una segunda barrera: **¿Contenido pendiente de revisión?** exige el valor exacto **En revision**. Una segunda respuesta APROBAR/RECHAZAR sobre un contenido ya resuelto no puede volver a ejecutar la acción crítica.

3. Gestión de errores y caminos infelices

Fallo	Detección	Persistencia / cierre seguro
Idea Semilla vacía	¿Idea Semilla válida? = FALSE	Crea Error tipo Datos incompletos. No crea consumo IA y termina la rama.
Fallo OpenAI	Nodo OpenAI configurado para continuar por salida de error	Crea Error IA, vincula ejecución/contenido, cierra Ejecución=Error y Contenido=Error.
Fallo Slack	Nodo Slack continúa por salida de error	Crea Error Slack, cierra Ejecución=Error y Contenido=Error; no existe revisión/publicación.
Respuesta HITL inválida	Solo APROBAR o RECHAZAR y debe existir thread_ts	Finaliza sin cambiar estado ni ejecutar publicación.
Decisión duplicada	Contenido debe continuar En revision	Finaliza sin repetir la decisión.

Seguridad, Resiliencia y Human-in-the-loop

Ecosistema Autónomo de Generación, Validación y Distribución de Contenidos - Verte Bien
Entrega Final - AI Automation | Coderhouse

4. Human-in-the-loop (HITL)

El HITL se implementa con Slack y un workflow independiente. El pipeline principal envía el borrador al canal de revisión y guarda el **message_timestamp** tanto en Contenidos como en la Ejecución exacta. Ese valor se convierte en la clave de correlación del proceso humano.

Etapas	Control
1. Solicitud	n8n envía Idea Semilla + Borrador y solicita APROBAR o RECHAZAR.
2. Respuesta humana	La persona responde dentro del hilo de Slack.
3. Validación de comando	Solo se aceptan APROBAR / RECHAZAR y se exige thread_ts.
4. Correlación	thread_ts se busca contra Slack Message TS en Contenidos y Ejecuciones.
5. Estado previo	El contenido debe seguir exactamente En revision.
6. Aprobación	Se marca Aprobado=true y Estado=Aprobado.
7. Control final	Se vuelve a comprobar Aprobado=true antes del nodo de publicación.
8A. Publicación	Solo la rama aprobada llega a Publicar Contenido Aprobado - Slack y Estado=Publicado.
8B. Rechazo	Estado=Rechazado, Aprobado=false; la rama nunca conecta con publicación.

Acción crítica: en esta implementación académica, la publicación final se simula mediante un mensaje Slack de contenido aprobado. La arquitectura demuestra el bloqueo previo a una acción crítica real; un conector de Instagram podría reemplazar ese nodo sin alterar el mecanismo HITL.

5. Pruebas de estrés ejecutadas

#	Prueba	Resultado esperado	Resultado observado
1	Contenido válido + APROBAR	Generar → HITL → Publicar → Exitoso	PASS: contenido Publicado y ejecución Exitosa.
2	Contenido válido + RECHAZAR	No publicar; cerrar Rechazado	PASS: contenido Rechazado y ejecución Rechazada.
3	Idea Semilla vacía	Registrar error sin llamar IA	PASS: Datos incompletos registrado antes de GPT.
4	Modelo OpenAI inválido	Capturar fallo API y cerrar seguro	PASS: Error IA registrado; contenido y ejecución en Error.
5	Canal Slack inválido	Capturar fallo de salida	PASS: Error Slack / channel_not_found; sin HITL ni publicación.
6	APROBAR duplicado en hilo resuelto	Bloquear segunda decisión	PASS: filtro de estado impidió reprocesamiento.

6. Protección de credenciales y evidencia pública

Las credenciales de Airtable, OpenAI y Slack permanecen administradas dentro del sistema de credenciales de n8n. En el video y las capturas no deben abrirse paneles que revelen API Keys, Personal Access Tokens o Signing Secrets. Los JSON exportados deben revisarse antes de publicarse en GitHub para confirmar que solo contengan referencias internas de credenciales.

La Shared View de Airtable utilizada como evidencia pública debe aplicar minimización: exponer métricas de monitoreo y ocultar campos operativos que no sean necesarios, por ejemplo Slack Message TS, mensajes técnicos extensos o identificadores internos. El enlace debe permanecer en modo lectura.

7. Resultado

El ecosistema aplica defensa en profundidad: filtro anti-loop, validación previa de datos, prompt restrictivo, salida estructurada, persistencia de errores, correlación exacta de HITL, control de estado y una segunda comprobación antes de la acción crítica. Las pruebas ejecutadas incluyen caminos felices e infelices y demuestran que un fallo no deriva silenciosamente en una publicación.